

# **14장 합성곱신경망: 컴퓨터비전 (2부)**

## **감사의 글**

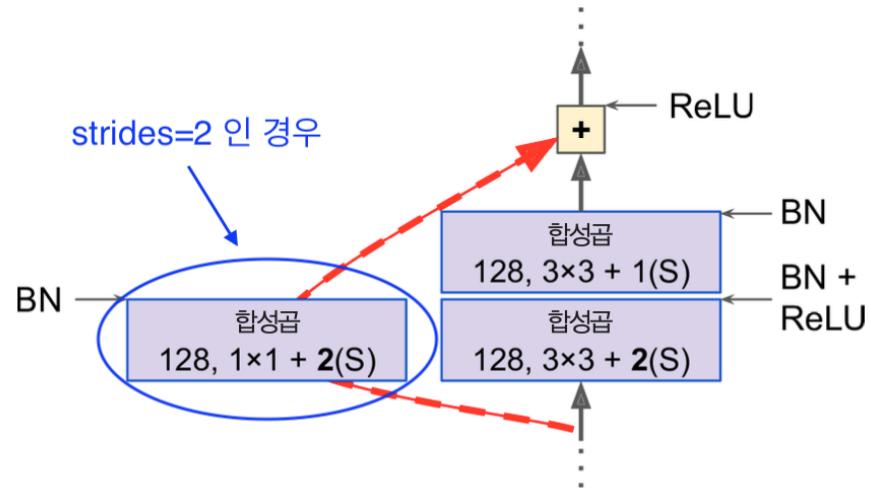
자료를 공개한 저자 오렐리앙 제롱과 강의준비에 필요한 자료를 지원한 한빛아카데미에게 진심어린 감사  
를 전합니다.

# ResNet-34 CNN 구현

- 앞서 소개된 대부분의 CNN 모델들을 케라스가 기본으로 지원함.
- 하지만 실제로 케라스로 구현하는 것도 대부분 매우 쉬움.

## 잔차 유닛(RU) 구현

- ResNet-34 모델에 사용되는 ResidualUnit 층을 직접 구현하는 것도 간단함.



- ResidualUnit 클래스 구성 요소
  - main\_layers: 오른쪽 모듈
  - skip\_layers: 왼쪽 모듈. 보폭이 1보다 큰 경우에만 합성곱 모델 적용.

```
DefaultConv2D = partial(keras.layers.Conv2D, kernel_size=3, strides=1,
                       padding="SAME", use_bias=False)

class ResidualUnit(keras.layers.Layer):
    def __init__(self, filters, strides=1, activation="relu", **kwargs):
        super().__init__(**kwargs)
        self.activation = keras.activations.get(activation)
        self.main_layers = [
            DefaultConv2D(filters, strides=strides),
            keras.layers.BatchNormalization(),
            self.activation,
            DefaultConv2D(filters),
            keras.layers.BatchNormalization()]
        self.skip_layers = []
        if strides > 1:
            self.skip_layers = [
                DefaultConv2D(filters, kernel_size=1, strides=strides),
                keras.layers.BatchNormalization()]
```

```
def call(self, inputs):
    # main_layers
    Z = inputs
    for layer in self.main_layers:
        Z = layer(Z)

    # skip_layers
    skip_Z = inputs
    for layer in self.skip_layers:
        skip_Z = layer(skip_Z)
    return self.activation(Z + skip_Z)
```

## ResNet-34 구현

- Sequential 클래스 활용
- 잔차 유닛을 하나의 층으로 취급 가능

```
model = keras.models.Sequential()
model.add(DefaultConv2D(64, kernel_size=7, strides=2,
                       input_shape=[224, 224, 3]))
model.add(keras.layers.BatchNormalization())
model.add(keras.layers.Activation("relu"))
model.add(keras.layers.MaxPool2D(pool_size=3, strides=2, padding="SAME"))
prev_filters = 64
for filters in [64] * 3 + [128] * 4 + [256] * 6 + [512] * 3:
    strides = 1 if filters == prev_filters else 2
    model.add(ResidualUnit(filters, strides=strides))
    prev_filters = filters
model.add(keras.layers.GlobalAvgPool2D())
model.add(keras.layers.Flatten())
model.add(keras.layers.Dense(10, activation="softmax"))
```

**케라스 제공 사전훈련된 모델 활용**

- 많은 모델이 keras.applications에서 기본제공됨.
  - ResNet 모델 변종
  - Inception-v3, Xception 등 GoogLeNet 모델 변종
  - VGGNet 모델 변종
  - MobileNet, MobileNetV2 등 모바일 전용 모델

**예제: ResNet-50 모델**

## 모델 불러오기

```
model = keras.applications.resnet50.ResNet50(weights="imagenet")
```

- 224x224 모양의 이미지를 입력값으로 사용해야 함.

## 주의사항: 입력 이미지 모양

- 모델에 따라 입력 이미지의 모양이 달리짐.
  - 입력모양 변경: `tf.image.resize()`, `tf.image.crop_and_resize()` 등 다양한 함수 이용 가능.
    - 일반적으로 가로, 세로 비율을 유지하지는 않음.

```
images_resized = tf.image.resize(images, [224, 224])
```

또는

## 주의사항: 입력 데이터 값

- 모델에 따라 입력 이미지에 사용되는 값은 0에서 1 또는 -1에서 1 사이로 스케일링 된 것을 기대.
- 모델마다 `preprocess_input()` 제공.
  - 이미지에 사용된 값이 0에서 255 사이인 것을 기대
  - 예를 들어, 이미지에 사용된 값이 0에서 1사이의 값이라면, 255를 곱해서 입력해 주어야 함.

```
inputs = keras.applications.resnet50.preprocess_input(images_resized * 255)
```

## 예측

```
Y_proba = model.predict(inputs)
```

## 예측결과 확인

- `decode_predictions()` 메서드 활용
  - 이미지별로 지정된 수 만큼의 최상위 예측 클래스를 보여줌.
- 아래 코드는 두 이미지 각각에 대한 최상위 3개의 클래스를 보여줌.
  - 클래스 수: 1,000개

```
top_K = keras.applications.resnet50.decode_predictions(Y_proba, top=3)
for image_index in range(len(images)):
    print("Image #{}".format(image_index))
    for class_id, name, y_proba in top_K[image_index]:
        print("  {} - {:.12s} {:.2f}%".format(class_id, name, y_proba * 100))
print()
```

- 결과
  - 정확하지는 않지만 사원(monastery), 데이지(daisy) 등 유사한 클래스가 탑 3 항목에 포함되었음.

Image #0

n03877845	-	palace	43.39%
n02825657	-	bell_cote	43.07%
n03781244	-	monastery	11.70%

Image #1

n04522168	-	vase	53.96%
n07930864	-	cup	9.52%
n11939491	-	daisy	4.97%

## **사전훈련된 모델 활용 전이학습**

- 이미지넷에 없는 이미지 클래스를 감지하는 분류기를 만들고자 하는 경우 활용

## **예제: 사전훈련된 Xception 모델 활용**

- 사전훈련된 Xception 모델을 활용한 꽃 이미지 분류기 모델 훈련하기

## 데이터 불러오기

- tensorflow\_datasets 모듈의 load() 함수 활용하여 샘플 데이터셋 불러오기

```
import tensorflow_datasets as tfds  
  
dataset, info = tfds.load("tf_flowers", as_supervised=True, with_info=True)
```

- tf\_flowers 데이터셋
  - 훈련 세트만 존재하는 데이터셋
  - 5개의 꽃 클래스: [ 'dandelion', 'daisy', 'tulips',  
'sunflowers', 'roses' ]
  - 샘플 수: 3,670

- 테스트 세트(10%), 검증 세트(15%), 훈련 세트(75%)로 분리하기

```
test_set_raw, valid_set_raw, train_set_raw = tfds.load(  
    "tf_flowers",  
    split=[ "train[:10%]", "train[10%:25%]", "train[25%:]" ],  
    as_supervised=True)
```

## 전처리

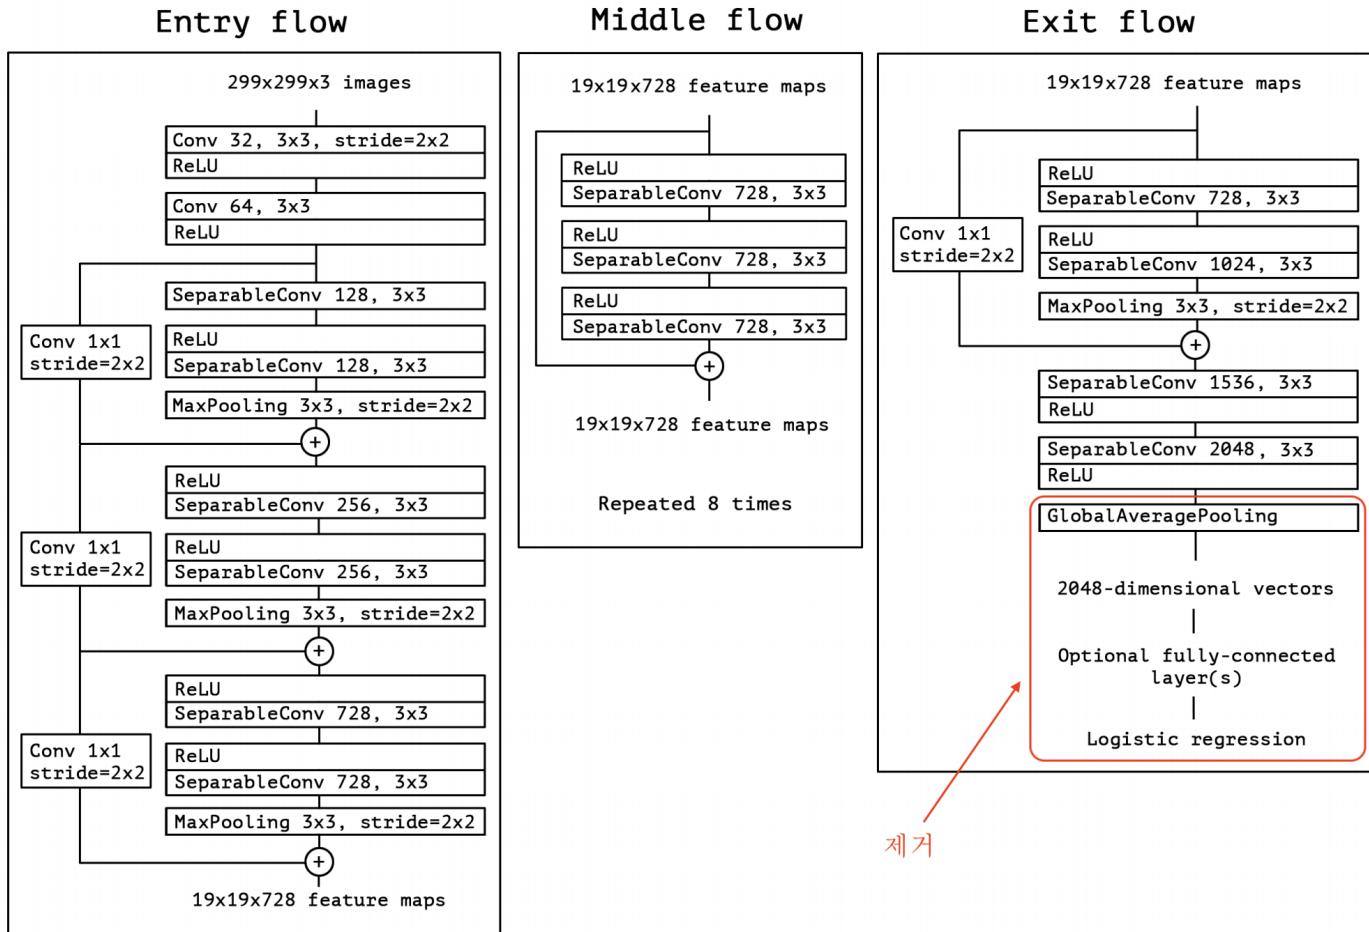
- 배치 활용: 크기는 32
- 섞기(shuffle) 실행
- randomize=True: 무작위적으로 사진자르기와 수평뒤집기 등을 활용한 데이터 증식
- 224x224 모양으로 변환 후 preprocess\_input() 메서드로 전처리 실행
- prefetch(1): 배치 미리 준비시키기

```
def preprocess(image, label, randomize=False):
    if randomize:
        cropped_image = random_crop(image)
        cropped_image = tf.image.random_flip_left_right(cropped_image)
    else:
        cropped_image = central_crop(image)
    resized_image = tf.image.resize(cropped_image, [224, 224])
    final_image = keras.applications.xception.preprocess_input(resized_image)
    return final_image, label

batch_size = 32
train_set = train_set_raw.shuffle(1000).repeat()
train_set = train_set.map(partial(preprocess, randomize=True)).batch(batch_size).
prefetch(1)
valid_set = valid_set_raw.map(preprocess).batch(batch_size).prefetch(1)
test_set = test_set_raw.map(preprocess).batch(batch_size).prefetch(1)
```

## ImageNet에서 사전훈련된 Xception 모델 활용

- 분리 합성곱 층들을 제외한 (최상위에 위치한) 층 제거
  - 전역평균 층
  - 밀집 출력층



<그림 출처: [Xception: Deep Learning with Depthwise Separable Convolutions](https://arxiv.org/pdf/1610.02357.pdf) (<https://arxiv.org/pdf/1610.02357.pdf>)>

- 최상위 몇 개의 층 제거 후 새로운 층 두 개 추가
  - 전역평균층
  - softmax 활성화함수를 사용하는 밀집 출력층

```
base_model = keras.applications.Xception(weights="imagenet",
                                           include_top=False)
avg = keras.layers.GlobalAveragePooling2D()(base_model.output)
output = keras.layers.Dense(n_classes, activation="softmax")(avg)
model = keras.models.Model(inputs=base_model.input, outputs=output)
```

**1차 훈련**

- 사전훈련된 층의 가중치를 동결 후 훈련
- 학습률: lr=0.2
- 성능: 검증 세트에 대한 정확도가 88% 정도

```
# 사전훈련된 층의 가중치 동결하기
for layer in base_model.layers:
    layer.trainable = False

# 컴파일 후 훈련 시작
optimizer = keras.optimizers.SGD(lr=0.2, momentum=0.9, decay=0.01)
model.compile(loss="sparse_categorical_crossentropy", optimizer=optimizer,
              metrics=["accuracy"])
history = model.fit(train_set,
                     steps_per_epoch=int(0.75 * dataset_size / batch_size),
                     validation_data=valid_set,
                     validation_steps=int(0.15 * dataset_size / batch_size),
                     epochs=5)
```

**2차 훈련**

- 사전훈련된 층의 가중치 동결 해제 후 다시 훈련
- 학습률 작게: lr=0.0.01
- 성능: 검증 세트에 대한 정확도가 94.3% 정도

```
# 사전훈련된 층의 가중치 동결 해제
for layer in base_model.layers:
    layer.trainable = True

# 재 컴파일 후 훈련 시작
optimizer = keras.optimizers.SGD(learning_rate=0.01, momentum=0.9,
                                 nesterov=True, decay=0.001)
model.compile(loss="sparse_categorical_crossentropy", optimizer=optimizer,
               metrics=["accuracy"])
history = model.fit(train_set,
                      steps_per_epoch=int(0.75 * dataset_size / batch_size),
                      validation_data=valid_set,
                      validation_steps=int(0.15 * dataset_size / batch_size),
                      epochs=40)
```

## **분류와 위치추정(classification and localization)**

- 사진에 포함된 꽃을 분류하면서 해당 꽃의 위치 추정하기
- 위치추정은 회귀 모델로 구현 가능
  - 탐색대상인 객체의 주위로 네모 모양의 경계상자(bounding box) 그리기
  - 네모상자의 중심좌표와 높이와 너비(세로와 가로), 즉, 네 개의 값을 예측해야 함.

## 경계상자 추정 모델 구현

- 앞서 사용된 분류 모델에 위치추정 기능을 갖는 출력층을 추가하면 됨.
  - 위치추정 출력층: 값예측을 위한 네 개의 뉴런 사용.

```
base_model = keras.applications.Xception(weights="imagenet",
                                            include_top=False)
avg = keras.layers.GlobalAveragePooling2D()(base_model.output)
class_output = keras.layers.Dense(n_classes, activation="softmax")(avg)
loc_output = keras.layers.Dense(4)(avg)
model = keras.models.Model(inputs=base_model.input,
                           outputs=[class_output, loc_output])
model.compile(loss=[ "sparse_categorical_crossentropy", "mse" ],
              loss_weights=[0.8, 0.2], # 어느 출력에 보다 집중할지 결정
              optimizer=optimizer, metrics=[ "accuracy" ])
```

## 경계상자 레이블링

- 경계상자 추정 모델을 (지도)학습시키려면 모든 이미지에 경계상자 레이블이 있어야 하거나 추가해야함.
- 하지만 가장 어려우면서 고비용이 요구되는 작업이 선행되어야 함.

## 경계상자 레이블링 도구 소개

- 오픈소스 프로그램
  - VGG Image Annotation
  - LabelImg
  - OpenLabeler
  - ImgLab
- 상용 프로그램
  - LabelBox
  - Supervisely

- 크라우드소싱(crowdsourcing) 플랫폼
  - Amazon Mechanical Turk
    - 아주 많은 양의 이미지에 경계상자 등 표기할 경우
    - 많은 준비작업이 요구됨.
  - 참조 논문: [Crowdsourcing in Computer Vision, Adriana Kovashka et al. \(https://arxiv.org/abs/1611.02145\)](https://arxiv.org/abs/1611.02145)

## 이미지 전처리

- 경계상자 레이블링 후 두 개의 레이블을 사용하는 이미지를 전처리해야 함. 모델에 입력되는 샘플의 형식은 다음과 같음.

(`images`, (`class_labels`, `bounding_boxes`))

## 경계상자 평가지표: IoU

- 경계상자 예측값들의 정확도 평가함수
- 전체 영역에서 겹치는 부분의 비율로 평가
- MSE 보다 높은 정확도 보임.

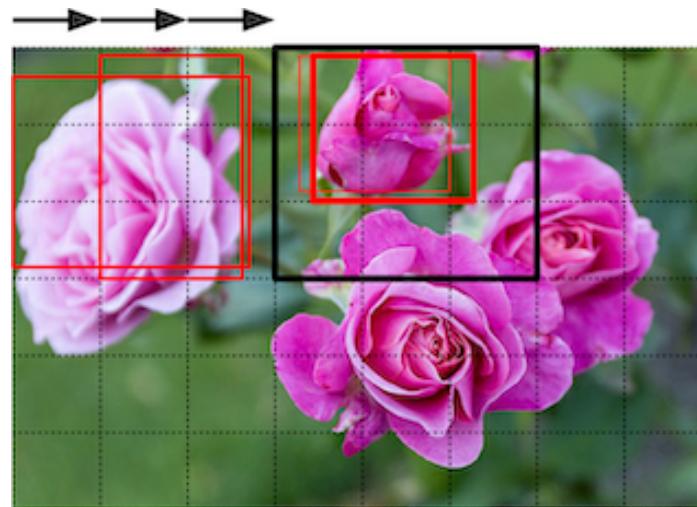


**객체탐지**

- 하나의 이미지에서 여러 개의 물체를 분류하고 위치를 추정하는 작업

## 기본 아이디어

- CNN 모델이 사진을 훑어 보도록 함.
  - 한 번 훑을 때마다 하나의 물체 탐색
- 탐색 영역의 크기를 변화시키며 물체 탐색
  - $3 \times 3$ ,  $4 \times 4$  등등
  - 그 중에 가장 적절한 탐색 결과를 이용하여 물체 탐지



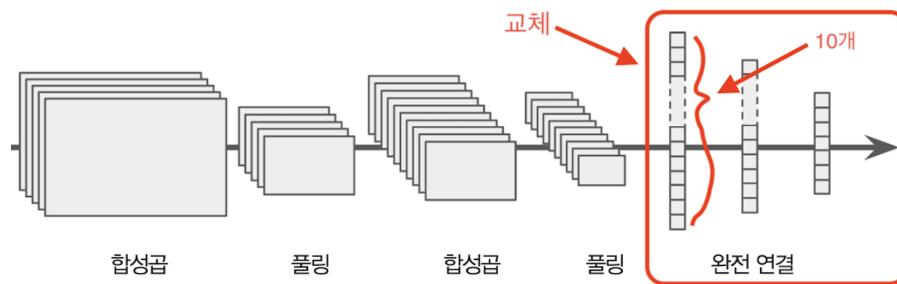
- 단점
  - 조금씩 다른 위치에서 동일한 물체를 여러 번 감지하여 불필요한 경계상자를 제거하는  
사후 작업 필요
    - 경계상자 안에 객체의 존재여부정도(objectness)를 계산하여 일정 값 이하  
의 경계상자 제거
  - CNN을 여러 번 작동시켜야 하기에 꽤 느림.

## 완전 합성곱신경망(Fully Convolutional Networks, FCN)

- CNN을 여러 번 작동시키는 단점 해소.
- 기본 아이디어: CNN의 최상위 밀집층을 합성곱 층으로 교체

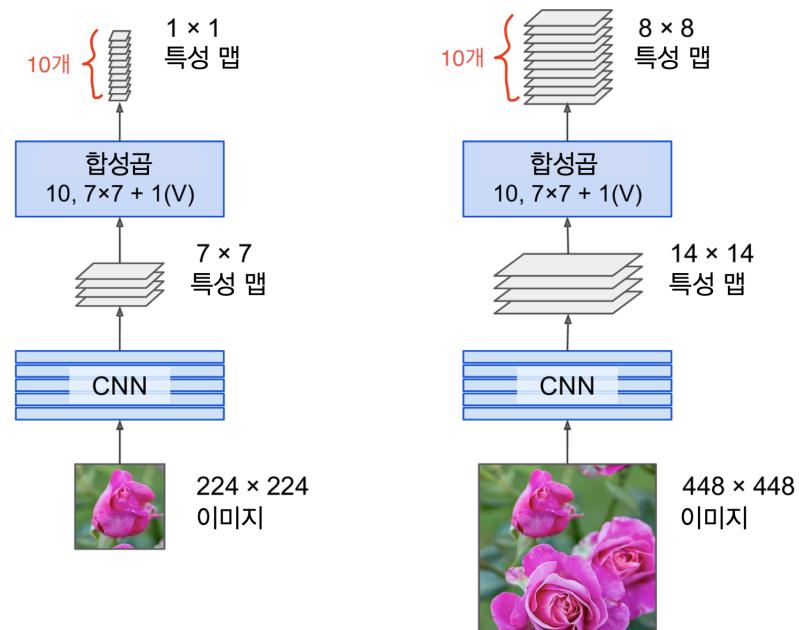
## 예제

- 가정: 아래 형식을 따르는 밀집층이 사용된 CNN 모델
  - 입력값:  $224 \times 224$  크기의 이미지
  - 마지막 합성곱 층/풀링 층의 결과:  $7 \times 7$  크기의 특성맵으로 이루어짐.
  - 밀집층: 10개의 뉴런으로 구성

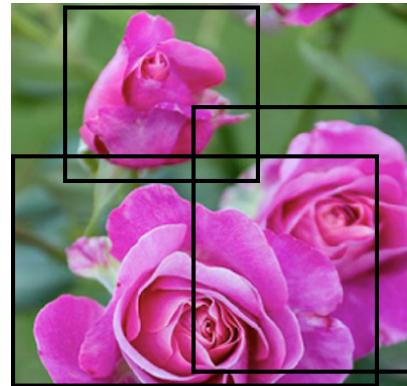


- 밀집층 교체

- 새로 추가되는 첫째 합성곱층:  $7 \times 7$  크기의 필터 10개 사용



- 다양한 크기의 입력사진을 다룰 수 있으며, 목적에 맞추어 다른 합성곱 층으로 구성 가능.
  - 예를 들어, 하나의 이미지에서 여러 객체의 탐지 가능



## FCN의 장점

- 이미지를 단 한 번만 처리
- YOLO(You Only Look Once): 인기 높은 객체탐지 기법

**YOLO**

- 2015년에 소개된 후 2016년 YOLOv2, 2018년 YOLOv3로 기능 향상됨.
- 심층신경망 훈련 전에 K-평균 비지도 학습을 이용하여 대상 주의로 앵커 박스(anchor box) 그림.
- 앵커 박스가 이후 훈련과정에서 보다 빠르고 정확한 경계상자를 예측하도록 도와줌.

- 학습된 모델은 실시간으로 비디오에 적용 가능할 정도로 빠름. 아래 데모 참조

```
In [3]: from IPython.display import YouTubeVideo  
# a talk about IPython at Sage Days at U. Washington, Seattle.  
# Video credit: William Stein.  
YouTubeVideo('MPU2HistivI')
```

Out[3]:



## YOLO 및 유사 모델 구현 예제

- [YoloV3 Implemented in TensorFlow 2.0](https://github.com/zzh8829/yolov3-tf2) (<https://github.com/zzh8829/yolov3-tf2>).
- [SSD: Single Shot MultiBox Detector](https://arxiv.org/abs/1512.02325) (<https://arxiv.org/abs/1512.02325>).
- [Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks](https://arxiv.org/abs/1506.01497) (<https://arxiv.org/abs/1506.01497>).

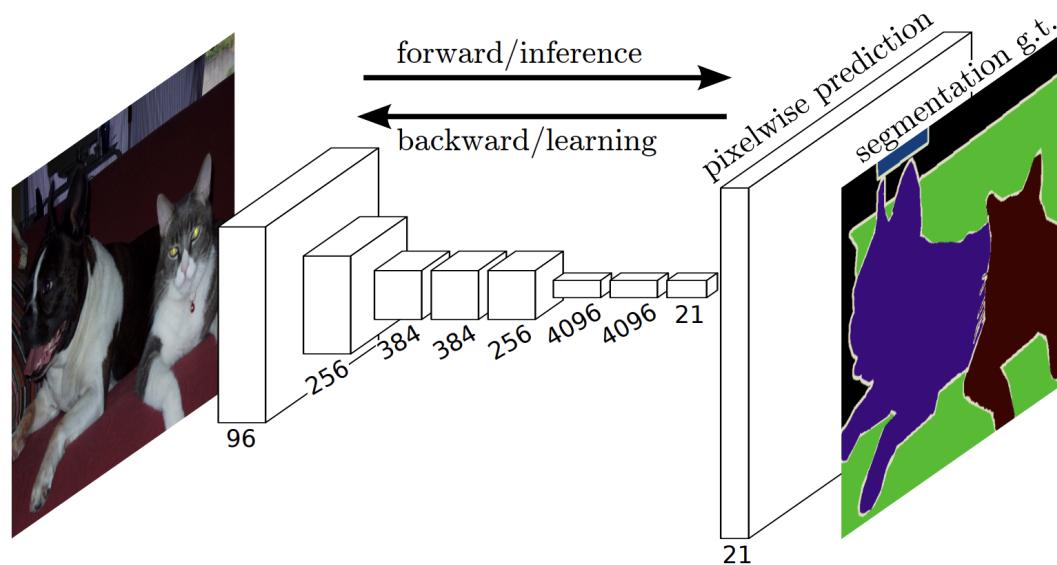
# 시맨틱 분할(Semantic Segmentation)

- 길, 자동차, 보행자, 건물 등 픽셀이 속한 객체에 따라 픽셀 분류하기
  - 동일 부류의 객체는 구별되지 않음. 자전거, 자동차 클래스 참조



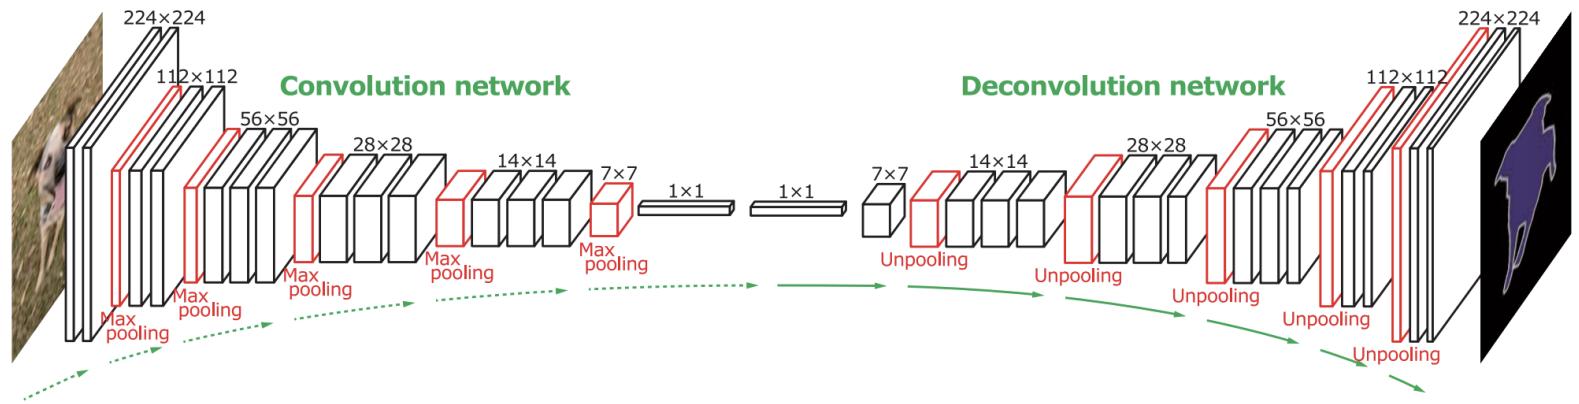
## 기본 아이디어

- FCN + 업샘플링(upsampling)
  - 아래 그림 참조



<그림 출처: [Fully Convolutional Networks for Semantic Segmentation](https://arxiv.org/pdf/1411.4038.pdf) (<https://arxiv.org/pdf/1411.4038.pdf>)>

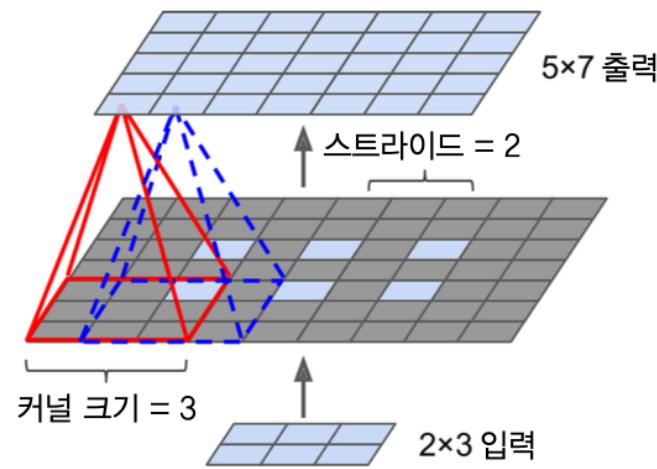
- upsampling = unpooling
- convolution <=> deconvolution



<그림 출처: [Learning Deconvolution Network for Semantic Segmentation](https://arxiv.org/abs/1505.04366)  
[\(https://arxiv.org/abs/1505.04366\)](https://arxiv.org/abs/1505.04366)>

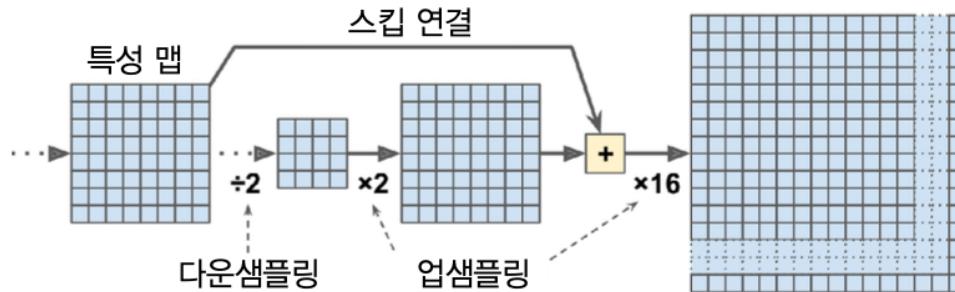
## **업샘플링과 스kip연결**

## 업샘플링



## 스킵연결

- 업샘플링만으로 정보 회복 어려움.
- 스kip연결을 이용하여 풀링 과정에서 잃은 정보를 어느 정도 회복시켜주면 학습에 많은 도움 줌.

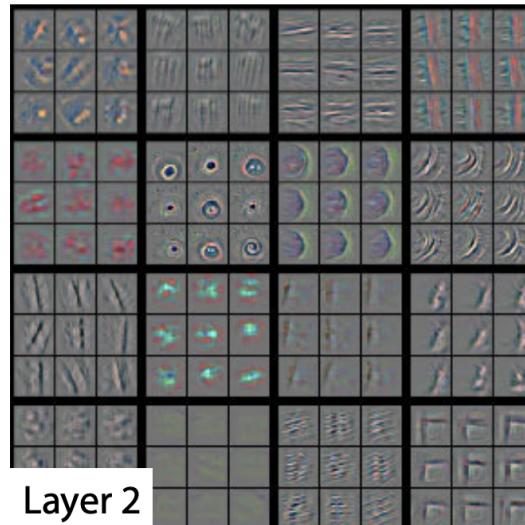
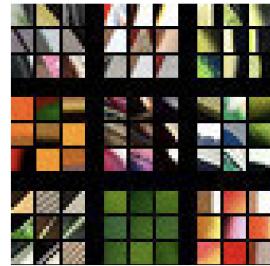


## **부록: 합성곱 신경망 시각화**

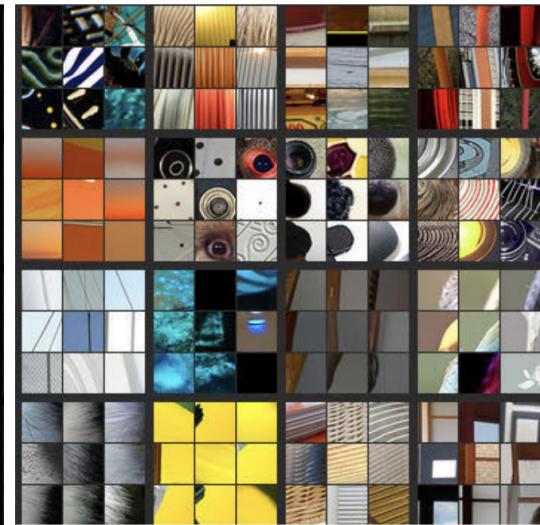
- Visualizing and Understanding Convolutional Networks  
(<https://arxiv.org/abs/1311.2901>)에서 합성곱 신경망의 각 층에서 이루어지는 작업을 시각화 하였음.
  - 얕은 층: 주로 직선 및 곡선, 색상 등의 낮은 수준의 특징이 활성화됨
  - 깊은 층: 보다 복잡하고 포괄적인 개체 정보가 활성화됨.

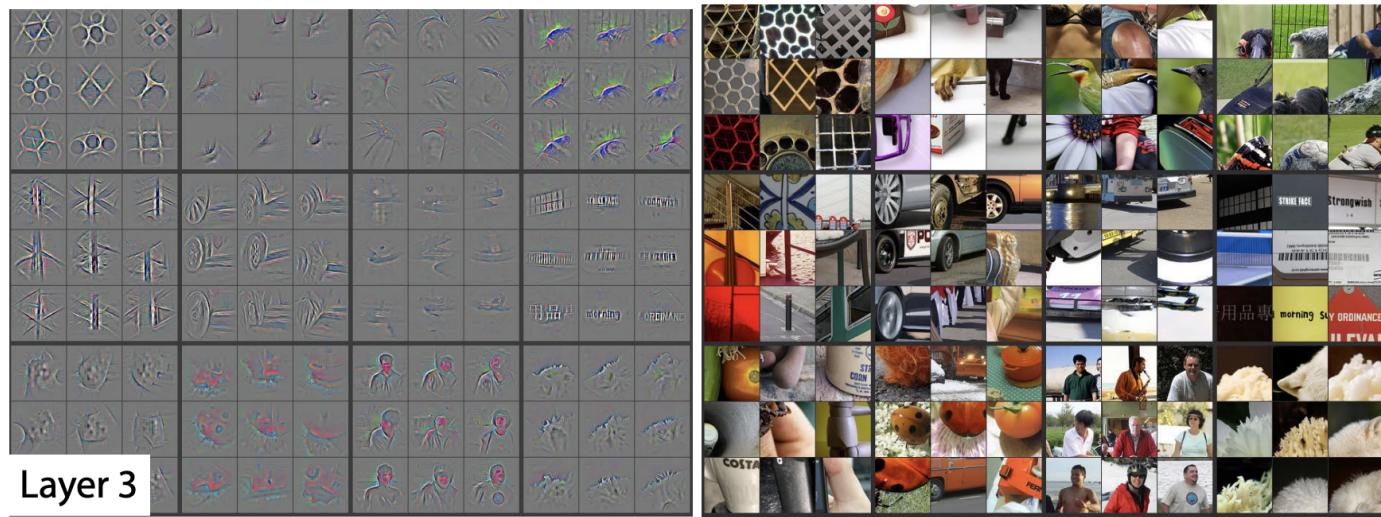


Layer 1

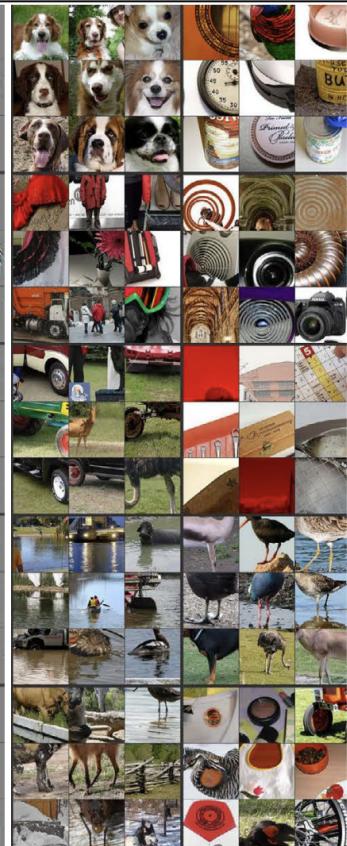
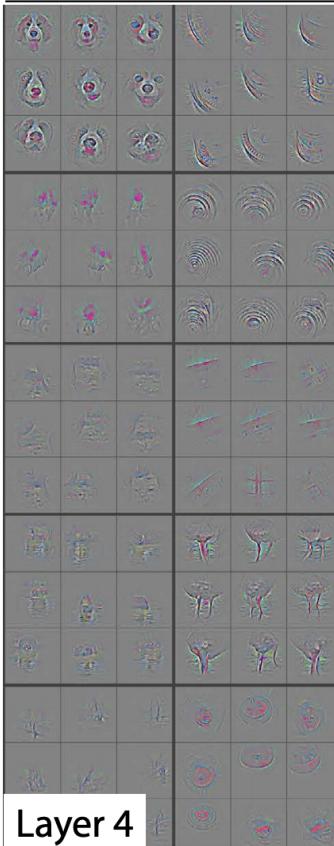


Layer 2





**Layer 4**



**Layer 5**

